

# TP Systèmes de recommandation

## SD-TSIA 211

Encadrement : Pascal Bianchi, Olivier Fercoq, Alex Lambert, Eugène Ndiaye et Umut Simsekli  
27 novembre 2017

Le TP se fait en binôme. Vous ferez un rapport accompagné des fonctions associées aux questions à envoyer au plus tard le 5 décembre sur le site pédagogique. Vous pouvez rendre le rapport sous forme d'un notebook python ou d'un fichier pdf.

Nous allouerons ensuite à chaque binôme un rapport à évaluer. Vous devrez donner une note en utilisant la grille d'évaluation fournie sur le site pédagogique.

## 1 Présentation du modèle

$U$  est l'ensemble des utilisateurs,  $I$  est l'ensemble des items (ici les films). Pour chaque couple  $(u, i)$ , soit l'utilisateur  $u$  n'a pas regardé le film  $i$  et nous n'avons pas de donnée, soit nous connaissons une note  $R_{u,i}$  du film  $i$  par l'utilisateur  $u$ .

Suivant [KBV09], on fait l'hypothèse qu'il existe un espace latent de caractéristiques jointes  $C$  tel que les interactions utilisateur-item sont des produits scalaires dans cet espace. Suivant ce modèle, on devrait avoir  $R_{u,i} \approx \sum_{c \in C} Q_{u,c} P_{c,i}$  où  $Q_{u,:}$  est une représentation de l'utilisateur  $u$  dans l'espace  $C$  et  $P_{:,i}$  est une représentation de l'item  $i$  dans ce même espace  $C$ . La force du modèle est de prédire une note probable que donnerait l'utilisateur  $u$  s'il regardait le film  $i$ , et donc de lui proposer les films qu'il n'a pas vus mais qu'il est susceptible d'aimer.

Il suffit ensuite d'entraîner ce modèle en utilisant des moindres carrés régularisés.

$$\begin{aligned} (\hat{P}, \hat{Q}) &= \arg \min_{P, Q} \frac{1}{2} \sum_{(u,i) \in K} \left( R_{u,i} - \sum_{c \in C} Q_{u,c} P_{c,i} \right)^2 + \frac{\rho}{2} \left( \sum_{u \in U, c \in C} Q_{u,c}^2 + \sum_{i \in I, c \in C} P_{c,i}^2 \right) \quad (1) \\ &= \arg \min_{P, Q} \frac{1}{2} \|1_K \circ (R - QP)\|_F^2 + \frac{\rho}{2} \|Q\|_F^2 + \frac{\rho}{2} \|P\|_F^2 \end{aligned}$$

où  $K$  est l'ensemble des couples  $(u, i)$  pour lesquels  $R_{u,i}$  est connu,  $\|\cdot\|_F$  est la norme de Frobenius,  $(1_K)_{u,i} = 0$  si  $(u, i) \notin K$  et  $(1_K)_{u,i} = 1$  si  $(u, i) \in K$ ,  $(A \circ B)_{u,i} = A_{u,i} B_{u,i}$  et  $\rho > 0$  est un paramètre de régularisation. Dans la suite, nous prendrons  $\rho = 0.3$  et  $C = \{0, \dots, 3\}$ .

Quand  $\rho = 0$  et  $K = U \times I$ , la solution de ce problème correspond à une SVD tronquée. Dans le cas général, il faut utiliser un algorithme d'optimisation.

### Question 1.1

Récupérer la base de données Movielens [HKBR99] sur le site suivant :

<http://files.grouplens.org/datasets/movielens/ml-100k.zip>.

Lancer la fonction `load_movielens` de `movielens_utils.py` avec le bon nom de fichier et vérifier que la matrice  $R$  retournée est bien de taille  $943 \times 1682$ . Que fait l'option `minidata` ?

### Question 1.2

Combien y a-t-il d'utilisateurs, de films référencés dans la base de données ? Quel est le nombre total de notes ?

### Question 1.3

La fonction objectif est-elle convexe ? Quel est son gradient ? Est-il lipschitzien ? Donner la constante de Lipschitz le cas échéant. On pourra remarquer que la fonction que l'on cherche à minimiser est un polynôme.

## 2 Trouver $P$ quand $Q_0$ est fixé

On initialise l'algorithme de résolution avec  $Q^0$  (resp.  $P^0$ ) défini comme les  $F$  vecteurs singuliers à gauche (resp. à droite) de  $R$  associés à ses  $|C|$  plus grandes valeurs singulières. Les valeurs manquantes de  $R$  seront fixées à 0 pour cette étape d'initialisation. Vous pourrez utiliser la fonction `scipy.sparse.linalg.svds`.

On cherche pour l'instant à résoudre le problème plus simple suivant :

$$g(P) = \frac{1}{2} \|1_K \circ (R - Q^0 P)\|_F^2 + \frac{\rho}{2} \|Q^0\|_F^2 + \frac{\rho}{2} \|P\|_F^2$$
$$P^1 = \arg \min_P g(P)$$

### Question 2.1

La fonction objectif  $g$  est-elle convexe ? Quel est son gradient ? On admettra que le gradient est lipschitzien de constante  $L_0 = \rho + \|(Q^0)^\top Q^0\|_F$ .

### Question 2.2

La fonction fournie `objective` calcule  $g(P)$ . Compléter cette fonction pour qu'elle calcule aussi  $\nabla g(P)$ . Vous pourrez vérifier votre calcul avec la fonction `scipy.optimize.check_grad` (vous aurez peut-être besoin des fonctions `numpy.reshape` et `numpy.ravel` car `check_grad` ne gère pas les variables matricielles).

### Question 2.3

Coder une fonction `gradient(g, P0, gamma, epsilon)` qui minimise une fonction  $g$  par la méthode du gradient à pas constant  $\gamma$  en partant du point initial  $P^0$  et avec le critère d'arrêt  $\|\nabla g(P_k)\|_F \leq \epsilon$ .

### Question 2.4

Utiliser la fonction codée à la question précédente pour minimiser la fonction  $g$  jusqu'à la précision  $\epsilon = 1$ .

### 3 Raffinements algorithmiques pour le problème à $Q_0$ fixé

#### Question 3.1

Rajouter une méthode de recherche linéaire à la méthode du gradient, de manière à s'affranchir du calcul de la constante de Lipschitz.

#### Question 3.2

Justifiez que l'on peut utiliser la méthode du gradient conjugué pour ce problème et codez-la.

#### Question 3.3

Comparer les performances des trois algorithmes.

### 4 Résolution du problème complet

#### Question 4.1

Résoudre le problème (1) par la méthode du gradient avec recherche linéaire jusqu'à la précision  $\epsilon = 100$ . À quoi correspond ce qui est retourné par l'algorithme ?

#### Question 4.2

Quand  $Q$  (resp.  $P$ ) est fixé, le problème est facile à résoudre. La méthode des moindres carrés alternés utilise ce fait et consiste en l'algorithme suivant :

---

```
for  $k \geq 1$  do
   $P_k \leftarrow \arg \min_P \frac{1}{2} \|1_K \circ (R - Q_{k-1}P)\|_F^2 + \frac{\rho}{2} \|Q_{k-1}\|_F^2 + \frac{\rho}{2} \|P\|_F^2$ 
   $Q_k \leftarrow \arg \min_Q \frac{1}{2} \|1_K \circ (R - QP_k)\|_F^2 + \frac{\rho}{2} \|Q\|_F^2 + \frac{\rho}{2} \|P_k\|_F^2$ 
end for
```

---

Montrer que la valeur de l'objectif décroît à chaque itération. En déduire qu'elle converge.

#### Question 4.3

Coder la méthode des moindres carrés alternés.

#### Question 4.4

Comparer la méthode du gradient avec recherche linéaire et la méthode des moindres carrés alternés. Est-ce que les solutions sont les mêmes ? Est-ce que la prédiction  $\hat{R} = QP$  est la même ? Est-ce que la valeur de l'objectif est la même ? Comment se comparent les temps de calcul ?

#### Question 4.5

Quel film recommanderiez-vous à l'utilisateur 300 ?

## Références

- [HKBR99] Jonathan L Herlocker, Joseph A Konstan, Al Borchers, and John Riedl. An algorithmic framework for performing collaborative filtering. In *Proc. of 22nd ACM SIGIR conference*, pages 230–237. ACM, 1999.
- [KBV09] Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix factorization techniques for recommender systems. *Computer*, (8) :30–37, 2009.